Performance dos modelos

Baseado na disciplina “Modelos de Predição em Saúde”
ministrada pelo Professor Alexandre Chiavegatto Filho (FSP/USP)

Nádia Cristina Pinheiro Rodrigues

Tipos de modelos preditivos

1 – Regressão: variável desfecho quantitativa

Ex: tempo de vida (em anos/meses/dias).

Performance avaliada pelo erro quadrático médio.

2 – Classificação: variável desfecho categórica

Ex: óbito, cura, abandono, etc.

Performance avaliada principalmente pela AUC-ROC

Por que não usar a acurácia para problemas de classificação

Acurácia => proporção de acerto

Exemplo: óbito

Se uma categoria ocorrer em 99% dos casos (não óbito), o algoritmo vai predizer que todos os casos estão nessa categoria

Acurácia: 99%

O modelo **não aprendeu nada sobre óbitos**, apenas “chutou” a partir da classe majoritária.

Mas essa métrica é enganosa em datasets desbalanceados.

O modelo não é útil para identificar óbitos, mesmo com alta acurácia.

Desafios das métricas de avaliação

- A maioria das métricas assume distribuição balanceada
- Deve-se escolher a métrica que capture melhor o que é importante no problema de predição em questão
- Existem técnicas de rebalanceamento que só podem ser aplicadas no conjunto treino. O conjunto teste (mundo real) não pode sofrer qualquer rebalanceamento.
- Na matriz de confusão, utilizar o threshold da proporção do desfecho na população.

Matriz de confusão

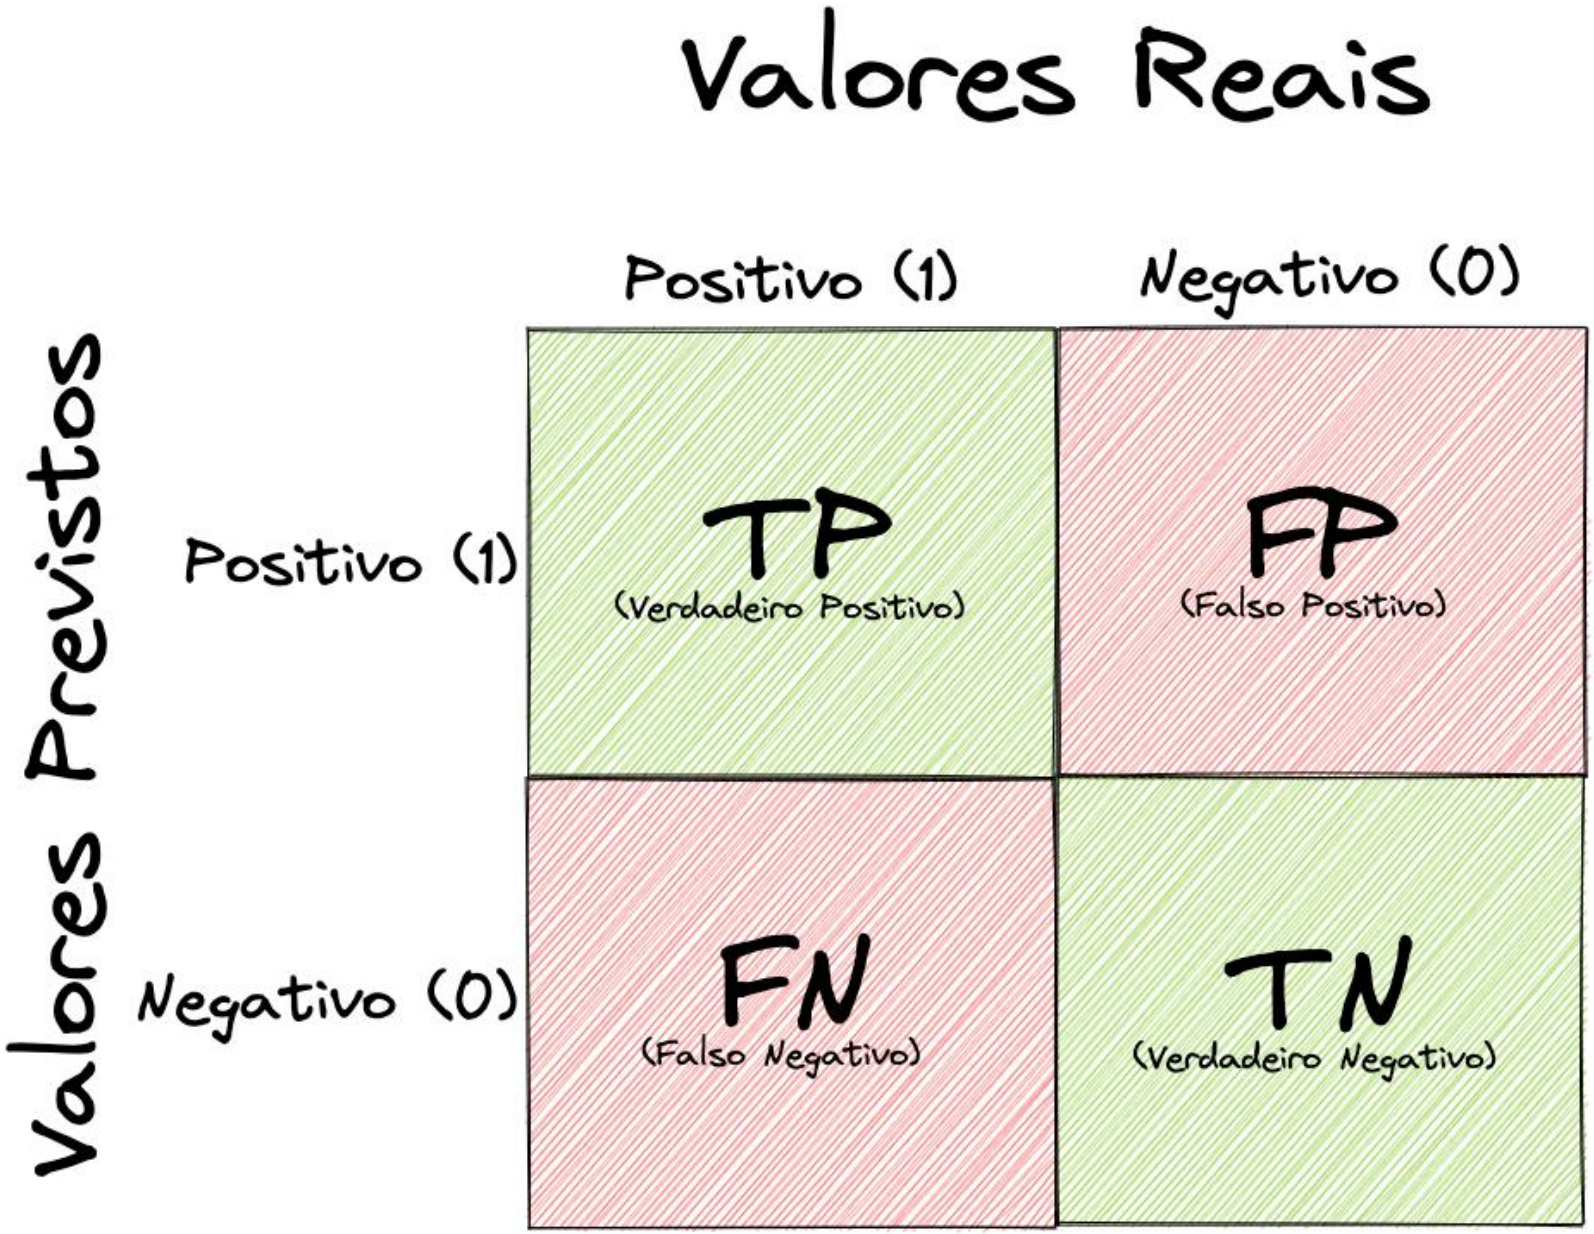

Matriz de confusão

Métrica	Expressão	Interpretação
Sensibilidade (Recall)	TP / (TP + FN)	Proporção de acertos entre o total de positivos reais
Especificidade	TN / (TN + FP)	Proporção de acertos entre o total de negativos reais
VPP (Precision)	TP / (TP + FP)	Proporção de acertos entre o total de previsões positivas
VPN	TN / (TN + FN)	Proporção de acertos entre o total de previsões negativas
PFP	FP / (FP + TN)	Proporção de falhas entre o total de positivos reais
PFN	FN / (FN + TP)	Proporção de falhas entre o total de negativos reais

Como escolher as métricas

Escolher as métricas de acordo com o problema de pesquisa.

Exemplo: predizer o abandono da TB. O que é mais importante?

Sen, Esp, VPP, VPN, PFP, PFN?

Desfecho positivo: abandono

Desfecho negativo: não abandono

Se o objetivo é evitar que pacientes com risco de abandono passem despercebidos, então precisamos captar o máximo de verdadeiros positivos (Sen) e, consequentemente, o mínimo de falsos negativos (PFN).

Como escolher as métricas

Exemplo: Predizer a indicação de cuidado paliativo

Desfecho positivo: sim, paciente deve iniciar tratamento paliativo

Desfecho negativo: não, o paciente ainda deve continuar no tratamento da doença

O objetivo é **diminuir os falsos positivos,** ou seja, não indicar o paciente para cuidado paliativo se ele ainda deve permanecer no tratamento.

É preciso confiar nas predições positivas do modelo -> a métrica principal neste caso é o **VPP**.

Alto VPP → Os pacientes que forem previstos para iniciar os cuidados paliativos devem de fato ser verdadeiro positivos

Ou seja, poucos pacientes devem ser **inadequadamente direcionados para paliativo**

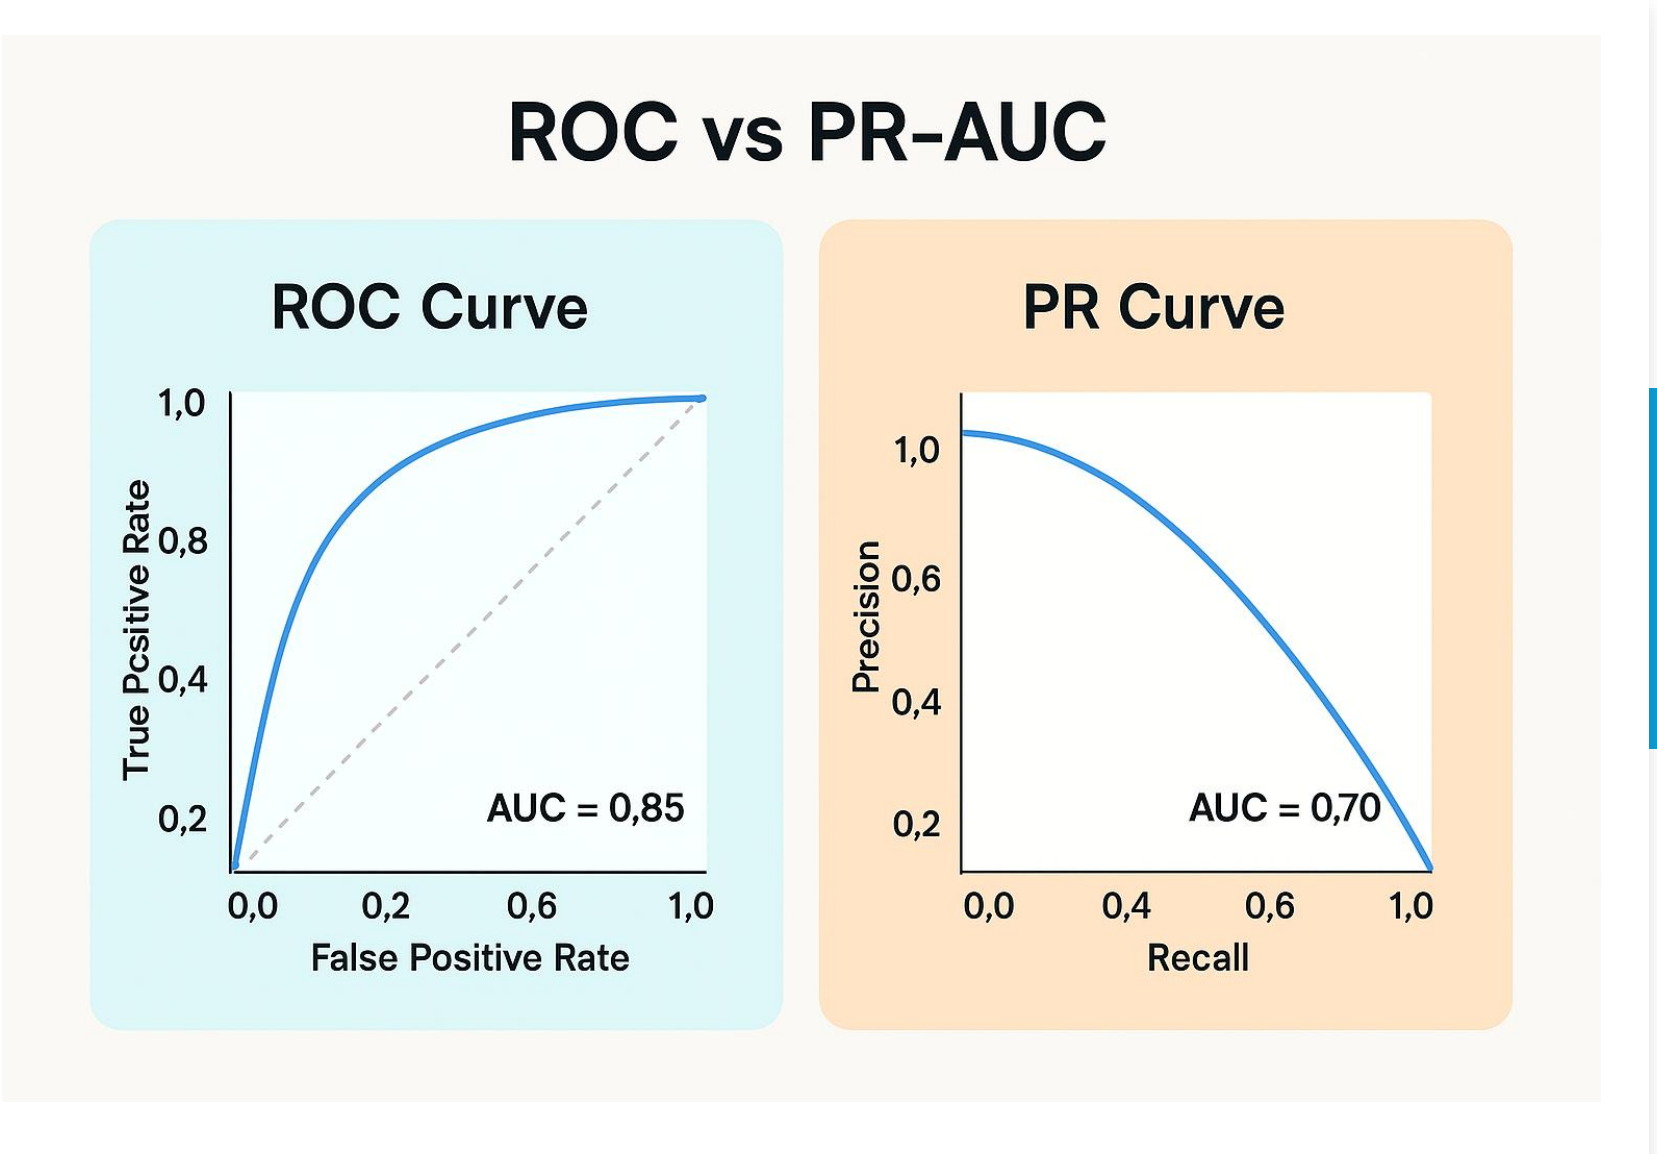

Métricas de ranking

Interpretação da AUC-ROC

AUC	Interpretação do modelo	Observação
1,0	Modelo perfeito	**Sensibilidade e especificidade máximas; separa totalmente positivos e negativos**
0,8 – 0,99	Modelo excelente	**Muito bom na discriminação das classes**
0,7 – 0,8	Modelo aceitável / bom	**Discriminação razoável; pode precisar de ajustes**
0,5 – 0,7	Modelo fraco	**Ligeiramente melhor que aleatório; pouca utilidade prática**
0,5	Modelo aleatório	**Sem poder de discriminação; “chute”**
< 0,5	Modelo invertido	**Classifica pior que aleatório**

AUC-ROC

A curva ROC resume o **comportamento do modelo para todos os thresholds possíveis** de classificação.

Cada ponto da curva representa uma combinação de Sens, Esp... para um threshold específico

- **Threshold** = valor de corte que decide se a previsão é positiva ou negativa

  Ex.: modelo prevê probabilidade de óbito = 0.3

  Se threshold = 0.5 a classificação do modelo será-> não óbito

  Se threshold = 0.2 → óbito

AUC-PR

Concentra o desempenho na classe minoritária

Indicada para desfechos raros

AUC-PR

AUC-PR	Interpretação do modelo	Observação
1,0	Modelo perfeito	**Captura todos os positivos sem falsos positivos**
0,8 – 0,99	Modelo excelente	**Muito bom em identificar positivos, poucos falsos positivos**
0,6 – 0,8	Modelo bom / aceitável	**Capta a maioria dos positivos, mas ainda há falsos positivos**
0,5 – 0,6	Modelo fraco	**Ligeiramente melhor que aleatório; pouca utilidade prática**
≤ 0,5	Modelo ruim / aleatório	**Pouco ou nenhum poder de discriminação; não confiável**

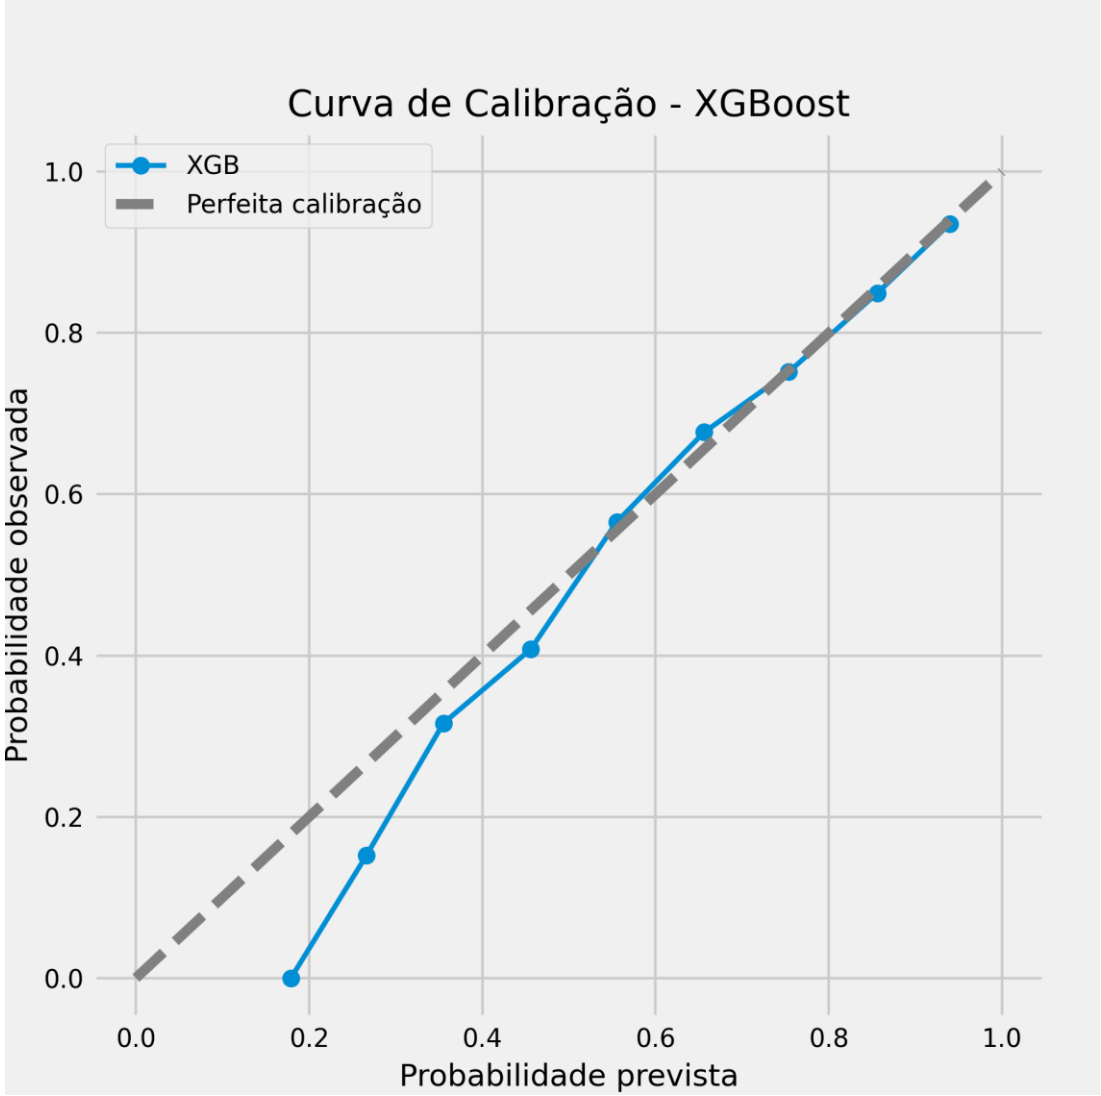

Calibração do modelo