

Interpretabilidade ou explicabilidade

Importância das variáveis do modelo final

Técnicas de explicabilidade

Interpretação/explicação dos modelos



O objetivo de uma predição **não é compreender a causalidade de um fenômeno** → é predizê-lo!



Se o interesse for causalidade, usar métodos causais.



Porém, é comum a necessidade de interpretação e explicação dos modelos.



Este tópico não deve ser aprofundado em pesquisas que visam prever o desfecho.

Interpretação/explicação dos algoritmos



É possível realizar alguma interpretação/explicação da importância das variáveis em modelos preditivos.



Sem confundir com estudos de inferência.



Interpretação em machine learning não é causalidade nem estudo de associação, mas sim uma forma de entender como o modelo realizou a predição.

Por que interpretar ou, aferir a importância das variáveis?

Para identificar a presença de preditores indesejáveis (**vazamento de dados**).

Para auxiliar na adesão dos profissionais de saúde

Estes aceitarão melhor se entenderem como foi tomada a decisão

Para garantir maior robustez

Para identificar possíveis preconceitos

Exemplo:

Na predição da probabilidade de ser admitido em uma empresa, o algoritmo pode estar usando raça, sexo ou universidade para aceitar ou rejeitar a admissão de novos funcionários.

Por que não interpretar o modelo?

Evitar manipular o sistema.

Exemplo:

Em um modelo que prediz a prioridade ou não do paciente receber o tratamento, um indivíduo pode saber de antemão que, para ser priorizado, ele deveria morar no Rio de Janeiro. Então, apesar de morar em Duque de Caxias, ele informa que mora no Rio de Janeiro.

Tipos de interpretação

- Intrínseca: utilizar algoritmos interpretáveis como modelos de regressão linear/logística
- Interpretação extrínseca (explicabilidade): utilizar técnicas que permitem retirar interpretação de algoritmos complexos após o treinamento.

Explicabilidade Extrínseca ou Pós-hoc

Uso de técnicas aplicadas após o treinamento de um modelo complexo para entender suas decisões.

Exemplos: Permutação, LIME, e SHAP (Shapley Values)

Permutação

Análise da mudança do erro de predição ao **permutar valores** da variável.

Variável é importante para predição se erro aumenta.

Se o modelo não utiliza essa variável o erro não muda.

LIME (Local Interpretable Model-agnostic Explanations)

Escolhe uma **predição específica**.

Cria pequenas mudanças nos dados.

Analisa como a predição muda.

Identifica **quais variáveis tiveram maior influência**.

Exemplo: Modelo prevê **alto risco de TB**.

LIME pode indicar que a predição ocorreu principalmente devido a:

- ✓ Idade elevada
- ✓ HIV positivo
- ✓ Histórico de abandono do tratamento



Como
funciona?

LIME

O modelo prevê **alto risco de TB** para um paciente.

O LIME cria **pequenas mudanças nos dados** do paciente.

Exemplos de alterações:

mudar a idade de **65 → 30 anos**

mudar **HIV positivo → negativo**

retirar **histórico de abandono do tratamento**



Como funciona?

LIME

O LIME observa como a previsão do modelo muda.

Cenário	Predição do modelo
Caso original	Alto risco de TB
Sem HIV positivo	Risco diminui
Sem abandono prévio	Risco diminui
Idade menor	Pequena redução do risco

LIME conclui quais variáveis tiveram maior influência na decisão:

HIV positivo → forte impacto no risco

Histórico de abandono → forte impacto

Idade elevada → impacto moderado

Shapley - Shapley Additive exPlanations

Baseado na teoria dos jogos

- O objetivo é identificar a contribuição individual de cada variável.
- O valor de Shapley é a contribuição média marginal de cada variável ao longo de todas as combinações possíveis de variáveis.

Valor de Shapley (SHAP) – Passo a passo

Se temos **3 variáveis: A, B e F**, o conjunto de **todas as combinações possíveis** (ou **coalizões**) é o **conjunto de todos os subconjuntos** dessas variáveis

Conjunto de todas as coalizões será $\{ \{ \}, \{A\}, \{B\}, \{F\}, \{A,B\}, \{A,F\}, \{B,F\}, \{A,B,F\} \}$

Quando estamos calculando o **valor de Shapley da variável F**, consideramos apenas as coalizões **que não contêm F**: $\{ \{ \}, \{A\}, \{B\}, \{A,B\} \}$

Para cada uma delas, comparamos a predição:

“sem F” e “com F”

Isso garante uma atribuição **justa e consistente** da contribuição da variável F.

Valor de Shapley (SHAP) – Passo a passo

Considerando uma variável **F** cujo impacto queremos interpretar no modelo...

Criar o conjunto de todas as combinações possíveis das variáveis

Geramos todas as combinações das variáveis de entrada — essas combinações são chamadas de **coalizões**.

Calcular a predição do modelo para cada coalizão sem F

Para cada coalizão que **não contém F**, calculamos a predição do modelo.

Calcular a predição do modelo para a mesma coalizão com F incluída

Depois, incluímos a variável **F** nessa coalizão e calculamos novamente a predição.

Calcular a contribuição marginal de F em cada coalizão


Para cada coalizão, calculamos a diferença:

$$\text{Contribuição marginal de } F = \text{Predição}(\text{com } F) - \text{Predição}(\text{sem } F)$$

Calcular o Valor de Shapley de F

O **valor de Shapley** é a **média de todas as contribuições marginais** de **F** calculadas no passo anterior, considerando todas as coalizões possíveis.

SHAP



SHAP

